گزارش فاز اول: آماده‌سازی، ممیزی کیفیت، توصیف داده‌ها و مصورسازی
Report) ۱ Phase (NHANES

فاطمه امینی زاده
دانشگاه صنعتی شریف

۱۱ آبان ۱۴۰۵

۱ مقدمه و منشأ داده‌ها Collection) Data & Source (Data

پایگاه داده‌ی مورد استفاده در این پژوهش مربوط به بررسی ملی سلامت و تغذیه ایالات متحده (NHANES - Cycle (L است که توسط مرکز ملی آمار بهداشت (NCHS) وابسته به CDC جمع‌آوری شده است.

- طرح پژوهش: مطالعه‌ی مقطعی مشاهداتی Study). Observational (Cross-sectional
- نحوه جمع‌آوری: ترکیبی از مصاحبه‌های خانگی (پرسشنامه‌های دموگرافیک و سبک زندگی) و معاینات بالینی/آزمایشگاهی در واحدهای سیار تخصصی .(MEC)
- فایل‌های ادغام‌شده:

۱. DEMO_L.XPT: اطلاعات دموگرافیک و وزن‌های نمونه‌برداری.
۲. BPXO_L.XPT: اندازه‌گیری‌های فیزیکی فشار خون.
۳. BMX_L.XPT: شاخص‌ها و اندازه‌گیری‌های تن‌سنجی (قد، وزن، .(BMI
۴. TCHOL_L.XPT: نتایج آزمایشگاهی کلسترول تام.
۵. SMQ_L.XPT: پرسشنامه استعمال دخانیات.
۶. PAQ_L.XPT: فعالیت بدنی و مدت زمان نشستن.
۷. ALQ_L.XPT: الگوی مصرف الکل.

۲ واحد مشاهده و ساختار ادغام Merging) & Structure (Data

- واحد مشاهده: هر ردیف نماینده‌ی یک فرد بزرگسال شرکت‌کننده است که با شناسه منحصربه‌فرد SEQN شناسایی می‌شود.
- سازوکار ادغام: تمامی فایل‌های فوق با استفاده از ادغام داخلی (Inner Join) بر روی کلید SEQN ترکیب شدند تا یک پایگاه داده‌ی یکپارچه تخت (Flat File) تشکیل شود.

آمار ادغام و تعاریف جمعیت تحلیلی:

- تعداد کل رکوردهای ادغام‌شده اولیه: $11,656$ فرد.
- معیار ورود به جمعیت تحلیلی: افراد بزرگسال با سن ۲۰ سال و بالاتر ($\text{RIDAGEYR} \geq 20$).
- تعداد افراد پس از اعمال فیلتر سنی: $7,025$ فرد (تعداد $4,631$ فرد زیر ۲۰ سال از تحلیل خروج یافتند).

۳ ممیزی کیفیت و پاکسازی داده‌ها (Data Cleaning) & Auditing

جهت رفع خطاهای منطقی و آماری، فرآیندهای زیر اعمال شد:

۱. شناسایی کدهای عدم پاسخ: کدهای ویژه پرسشنامه‌ای نظیر ۷۷۷۷ (Refused) و ۹۹۹۹ (Don't Know) در متغیرهای مربوط به فعالیت بدنی (PAD680) و دخانیات (SMD641) شناسایی و به مقادیر گم‌شده تبدیل شدند.

۲. بررسی محدوده‌های منطقی:

- مقادیر غیرممکن در وزن بدن ($\text{BMXWT} \leq 0$ یا $\text{BMXWT} > 250\text{kg}$) به مقادیر گم‌شده تبدیل شدند.
- میزان زمان نشستن (PAD680) در محدوده منطقی ۰ تا ۱۴۴۰ دقیقه در روز اعتبارسنجی شد.
- کلسترول تام ($\text{LBXTC} \leq 0$) کنترل گردید.

۳. اعتبارسنجی منطقی فشار خون:

- رکوردهایی که در آن‌ها فشار خون دیاستولیک بزرگتر یا مساوی فشار خون سیستولیک بود ($\text{BPXODI۱} \geq$ BPXOSY۱) یا مقادیر صفر/منفی داشتند، نامعتبر تشخیص داده شده و پاکسازی شدند.
- متغیر ترکیبی میانگین فشار خون سیستولیک (BPX_SY_MEAN) از میانگین سه نوبت اندازه‌گیری (BPXOSY1, BPXOSY2, BPXOSY3) برای هر فرد محاسبه گردید.

۴ طرح نمونه‌گیری و مقایسه برآوردهای خام و وزن‌دار (Sampling Weights) Analysis)

به دلیل استفاده NHANES از طرح نمونه‌گیری احتمالی چندمرحله‌ای، طبقه‌بندی‌شده و خوشه‌ای، ضریب شانس انتخاب افراد متغیر است. برای برآورد دقیق شاخص‌های جامعه، از وزن‌های معاینه بالینی (WTMEC2YR) استفاده شد.
مقایسه‌ی میانگین کلسترول تام (**LBXTC**):

- میانگین خام (Unweighted Mean): 187.42mg/dL
- میانگین وزن‌دار جامعه (Weighted Mean): 188.15mg/dL

تحلیل: تفاوت موجود میان میانگین خام و وزن‌دار نشان‌دهنده‌ی اثر طرح نمونه‌گیری پیچیده و ضرورت استفاده از وزن‌های آماری برای تعمیم نتایج به کل جمعیت بزرگسالان ایالات متحده است.

۵ شاخص‌های آماری توصیفی (Descriptive Statistics)

خلاصه‌ای از شاخص‌های مرکزی و پراکندگی متغیرهای کمی اصلی پژوهش در جدول زیر ارائه شده است:

متغیر	تعداد (N)	میانگین (μ)	انحراف معیار (σ)	میانه (Q_2)	چارک اول (Q_1)	چارک سوم (Q_3)
خص توده بدنی (BMI)	6,450	29.85	7.21	28.60	24.70	33.80
ن فشار خون سیستولیک	5,863	122.93	18.08	120.00	110.33	132.67
کلسترول تام (mg/dL)	5,621	187.42	41.35	184.00	158.00	212.00
ن نشستن روزانه (min)	5,710	375.40	210.15	360.00	210.00	480.00

۶ مقایسه‌ی توصیفی بین گروه‌ها (Descriptive Group Comparison)

برای بررسی اولیه تفاوت‌های بین‌گروهی بدون ادعای استنباط آماری، میانگین و میانه‌ی فشار خون سیستولیک بر حسب جنسیت مقایسه گردید:

جنسیت	تعداد (N)	میانگین فشار سیستولیک (mmHg)	انحراف معیار	میانه (mmHg)
مردان (Men)	2,646	125.35	16.84	123.00
زنان (Women)	3,217	120.94	18.81	117.33

نتیجه توصیفی: میانگین فشار خون سیستولیک در مردان بزرگسال حدود 4.41mmHg بالاتر از زنان است؛ همچنین پراکندگی فشار خون در زنان اندکی بیشتر از مردان مشاهده شد.

۷ مصورسازی داده‌ها (Data Visualizations)

چهار نمودار استاندارد جهت تبیین توزیع‌ها و روابط بین متغیرها تولید و در پوشه /figures ذخیره شدند:

۱. **01_BMI_Histogram.png** (توزیع BMI): نمایش چولگی به راست در توزیع شاخص توده بدنی که تمرکز افراد را در محدوده اضافه وزن و چاقی نشان می‌دهد.

۲. **02_BP_by_Gender_Boxplot.png** (باکس‌پلات فشار خون بر حسب جنسیت): مقایسه چارک‌ها، میانه‌ها و داده‌های پرت فشار خون سیستولیک در دو گروه مردان و زنان.

۳. **03_Smoking_Status_Barchart.png** (نمودار ستونی وضعیت استعمال سیگار): توزیع فراوانی افراد در سه طبقه مصرف روزانه، گاه‌به‌گاه و غیرسیگاری.

۴. **04_BMI_vs_BP_Scatter.png** (نمودار پراکنش BMI در برابر فشار خون): بررسی الگوی همبستگی مثبت اولیه میان افزایش BMI و افزایش فشار خون سیستولیک.

۸ نهایی‌سازی سؤال پژوهش (Research Question Formulation)

با توجه به ممیزی داده‌ها و حجم نمونه‌ی پاکسازی‌شده مناسب ($N \approx 5,800$)، سؤال نهایی پژوهش به شرح زیر تثبیت می‌گردد:

> «بررسی نقش پیش‌بینانه و ارتباط شاخص توده بدنی (BMI)، سن و عوامل سبک زندگی (سیگار کشیدن و کم‌تحرکی) بر روی میزان فشار خون سیستولیک در جمعیت بزرگسالان ایالات متحده (با کنترل عامل جنسیت).»

دلیل مناسب بودن پایگاه داده: پایگاه داده NHANES به دلیل دارا بودن اندازه‌گیری‌های استاندارد بالینی فشار خون (به جای خوداظهاری) و حجم نمونه بالا و نماینده‌ی کشوری، بستر کاملاً معتبری برای پاسخ به این سؤال پژوهشی فراهم می‌سازد.