گزارش رسمی فاز دوم: احتمال، توزیع‌های احتمالی و وزن‌های پیمایش

پروژه تحلیل داده‌های NHANES (۲۰۲۱ – ۲۰۲۳) – مسیر الف

فاطمه امینی‌زاده
دانشگاه صنعتی شریف

۲۵ آبان ۱۴۰۵

---

۱ مقدمه و ساختار کد اجرایی

در این فاز اسکریپت پایتون پروژه (main3.py) توسعه یافته است تا داده‌های تمیزشده فاز اول را وارد فضای احتمال کند. در این تحلیل، رویدادهای بالینی، احتمالات شرطی در زیرگروه‌ها، تقریب نرمال، مدل دوجمله‌ای شمارش، قضیه بیز و اثر وزن‌های نمونه‌گیری پیمایش بر برآورد احتمال محاسبه و نمودارهای متناظر در پوشه figures ذخیره شده‌اند.

۱.۱ نمودار روند اجرای کد (Flowchart)

نمودار زیر گام‌های اجرایی پیاده‌سازی شده در کد پایتون فاز دوم را نشان می‌دهد:

Load & Clean Merged Analytical Data ($N = 5,805$)
↓
Define Events: Hypertension (H) & Obesity (A)
↓
Marginal, Joint & Conditional Probabilities (Subgroups: Gender & Age)
↓
Empirical Independence Evaluation & Bayes' Theorem Update
↓
Binomial Model Simulation ($n = 20$) vs Theoretical PMF
↓
Continuous Distribution Analysis: Expected Value, Variance & Normal QQ-Plot
↓
Covariance Evaluation (BMI vs SBP) & Unweighted vs Weighted Proportions

۲ توضیح کارهای انجام‌شده در کد

بر اساس کد اجرا شده، اقدامات زیر به ترتیب انجام شده است:

۱. تعریف رویدادها و متغیرهای تصادفی: رویداد پرفشاری خون (H) بر اساس میانگین فشار خون سیستولیک مساوی یا بزرگتر از ۱۳۰ میلی‌متر جیوه و رویداد چاقی (A) بر مبنای شاخص توده بدنی مساوی یا بیشتر از ۳۰ تعریف شدند.

۲. محاسبه احتمالات حاشیه‌ای، مشترک و شرطی (الزام الف—۱): احتمال پرفشاری خون $P(H) = 0.2963$، احتمال چاقی $P(A) = 0.4091$ و احتمال توأم $P(H \cap A) = 0.1263$ به دست آمد. همچنین شیوع در مردان (0.3257) بالاتر از زنان (0.2721) و در افراد بالای ۵۰ سال (0.4081) به مراتب بالاتر از زیر ۵۰ سال (0.1189) مشاهده شد.

۳. بررسی مفهوم استقلال آماری: حاصل‌ضرب احتمالات حاشیه‌ای $P(H) \times P(A) = 0.1212$ با احتمال تجربی توأم (0.1263) مقایسه شد که اختلاف ناچیز 0.0051 نشان داد در کل جمعیت دو رخداد از نظر خام تفکیک‌پذیرند، اما عامل سن به شدت احتمال شرطی را تغییر می‌دهد.

۴. به‌روزرسانی با قضیه بیز: احتمال چاق بودن به شرط ابتلا به پرفشاری خون محاسبه شد ($P(A \mid H) = 0.4262$) که با فراوانی تجربی مستقیم یکسان بود.

۵. مدل دوجمله‌ای برای شمارش (الزام الف—۲): با ۱۰۰۰ بار شبیه‌سازی کشیدن نمونه‌های تصادفی به حجم $n = 20$، توزیع شمارش مبتلایان با مدل دوجمله‌ای مقایسه و نمودار 05_Binomial_Comparison.png ذخیره شد.

۶. امید ریاضی، واریانس و تقریب نرمال (الزام الف—۳): میانگین فشار سیستولیک (122.93mmHg)، واریانس (326.92) و انحراف معیار (18.08) به دست آمد. چولگی مثبت (0.937+) و نمودار Q-Q نشان داد توزیع در بخش مرکزی به نرمال نزدیک است ولی در دم راست انحراف دارد.

۷. کوواریانس و جهت رابطه: کوواریانس مثبت (3.518+) میان BMI و فشار سیستولیک محاسبه شد و نمودار پراکنش آن در پوشه ذخیره شد.

۸. نقش وزن‌های پیمایش (الزام الف—۴): شیوع خام نمونه‌ای (29.69%) با شیوع وزن‌دار تعمیم‌یافته به کل جامعه (25.25%) مقایسه شد و ضرورت وزن‌دهی بررسی گردید.