گزارش فاز اول: شناخت مطالعه، داده و آمار توصیفی

پروژه درس آمار — مسیر الف: NHANES ۲۰۲۱-۲۰۲۳

نام دانشجو: فاطمه امینی‌زاده
شماره دانشجویی: ۴۰۲۱۰۹۷۱۸
شناسه پروژه: NHANES_Project

۱۱ آبان ۱۴۰۵

چکیده

این گزارش شامل نتایج تحلیل‌های فاز اول پروژه درس آمار بر روی مجموعه داده NHANES ۲۰۲۱-۲۰۲۳ است. در این فاز، پس از ممیزی کامل منشأ داده‌ها و سازوکار نمونه‌گیری، فایل‌های دموگرافیک، تن‌سنجی، فشارخون، پرسشنامه‌ها و داده‌های آزمایشگاهی براساس شناسه یکتای SEQN ادغام گردیدند. جامعه تحلیلی پروژه به افراد بزرگسال بالای ۲۰ سال محدود شده و ممیزی کیفیت داده‌ها، بررسی الگوهای داده‌های گمشده، توزیع‌های تجربی متغیرها و مقایسه شاخص‌های آماری خام و وزن‌دار انجام گرفت.

۱ شناخت مطالعه و منشأ داده‌ها

۱.۱ منشأ داده و سازوکار جمع‌آوری

داده‌های مورد استفاده در این پروژه متعلق به پیمایش ملی سلامت و تغذیه ایالات متحده (NHANES) مربوط به دوره اوت ۲۰۲۱ تا اوت ۲۰۲۳ است که توسط مرکز ملی آمار سلامت (NCHS) منتشر شده است. این مطالعه، یک پیمایش مشاهده‌ای مقطعی با طرح نمونه‌گیری احتمالی پیچیده چندمرحله‌ای است که جهت ارزیابی وضعیت سلامت و تغذیه جمعیت غیرمستقر طراحی گردیده است.

۲.۱ واحد مشاهده و ساختار داده

واحد مشاهده در این داده‌ها هر شرکت‌کننده یکتا می‌باشد که با شناسه منحصربه‌فرد SEQN شناسایی می‌شود. هیچ مشاهده تکراری به ازای هر سطر وجود ندارد.

۳.۱ طرح نمونه‌گیری و قابلیت تعمیم

نمونه‌گیری NHANES شامل خوشه‌بندی، طبقه‌بندی (Stratification) و نمونه‌گیری با احتمال ناهمسان است. بنابراین افراد موجود در نمونه، شانس انتخاب متفاوتی دارند. برای تعمیم درست نتایج به جمعیت کل بزرگسالان ایالات متحده، استفاده از وزن‌های نمونه‌گیری (WTINT2YR / WTMEC2YR) الزامی است.

۲ ادغام فایل‌ها و تعریف جمعیت تحلیلی

۱.۲ فایل‌های مورد استفاده و کلید ادغام

فایل‌های مورد استفاده در این فاز عبارتند از:

- DEMO_L: اطلاعات دموگرافیک و وزن‌های نمونه‌گیری
- BMX_L: اندازه‌گیری‌های تن‌سنجی (از جمله BMI)
- BPXO_L: داده‌های معاینه فشارخون

- ALQ_L، SMQ_L، PAQ_L، SLQ_L: پرسشنامه‌های خواب، فعالیت بدنی، دخانیات و الکل
- TCHOL_L: اندازه‌گیری کلسترول تام خون

تمامی فایل‌ها بر اساس شناسه مشترک SEQN با اتصال چپ (Join Left) به فایل پایه دموگرافیک متصل گردیدند.

۲.۲ معیارهای ورود و خروج (معرفی جمعیت تحلیلی)

جریان حذف و انتخاب افراد در جدول زیر آورده شده است:

جدول ۱: فرایند غربالگری و تعیین حجم نمونه تحلیلی

مرحله غربالگری	تعداد افراد باقی‌مانده
تعداد کل شرکت‌کنندگان در دوره ۲۰۲۱-۲۰۲۳	۱۱،۵۷۸
اعمال شرط سن (سن بالای ۲۰ سال)	۶،۸۹۲
حذف افراد فاقد اندازه‌گیری فشارخون (BPXSY1)	۶،۳۴۰
حذف افراد فاقد شاخص BMI (BMXBMI)	۶،۱۲۵

۳ ممیزی کیفیت داده‌ها و آمار توصیفی

۱.۳ ممیزی داده‌های گمشده و مقادیر غیرممکن

در متغیرهای کلیدی نظیر فشارخون سیستولیک و BMI، کدهای ویژه و مقادیر نامشخص بررسی و با داده‌های گمشده استاندارد جایگزین شدند. نرخ گمشدگی در متغیرهای آزمایشگاهی نظیر کلسترول تام به دلیل انجام آزمایش بر روی زیرمجموعه نمونه، بالاتر از سایر متغیرها است.

۲.۳ مقایسه خلاصه خام و وزن‌دار

جهت بررسی اثر طرح نمونه‌گیری و وزن‌ها، شاخص‌های توصیفی به دو صورت ساده (خام) و وزن‌دار محاسبه گردیدند:

جدول ۲: مقایسه برآوردهای توصیفی خام و وزن‌دار در جمعیت تحلیلی

متغیر	میانگین خام (SD)	میانگین وزن‌دار (SE)
فشارخون سیستولیک (mmHg)	۴.۱۲۶ (۲.۱۸)	۸.۱۲۴ (۶.۰)
شاخص توده بدنی - BMI (kg/m^2)	۸.۲۹ (۷.۶)	۱.۲۹ (۳.۰)
سن (سال)	۶.۴۸ (۱.۱۷)	۹.۴۶ (۵.۰)

همانطور که ملاحظه می‌شود، برآوردهای وزن‌دار به دلیل تعدیل عدم پاسخ و شانس انتخاب ناهمسان در نمونه‌گیری، تفاوت‌های معناداری با خلاصه‌های خام نشان می‌دهند که اهمیت لحاظ وزن‌های پیمایش در فازهای استنباطی بعدی را تایید می‌کند.

۴ جمع‌بندی فاز اول

در فاز اول، ساختار داده‌ها بشناخته شد، ادغام بر اساس کلید SEQN انجام گرفت و جمعیت تحلیلی بزرگسالان بالای ۲۰ سال تثبیت شد. در فاز بعدی (فاز دوم)، توزیع‌های احتمالی، احتمال‌های شرطی و استقلال متغیرهای اصلی بررسی خواهند شد.